

Тема 2. Заняття 1

**Основи збору та зберігання даних для інформаційно-аналітичного
забезпечення органів військового управління**

Навчальні матеріали

2026

Table of Contents

1 Загальна характеристика заняття

Вид заняття: групове заняття.
Рекомендована тривалість: 2 академічні години.

1.1 Навчальні питання

1. Основи збору даних для інформаційно-аналітичного забезпечення органів військового управління.
2. Основи зберігання даних для інформаційно-аналітичного забезпечення органів військового управління.

1.2 Мета заняття

Сформувати у слухачів системне розуміння процесів отримання, перевірки, передавання, накопичення та зберігання даних, які використовуються для інформаційно-аналітичного забезпечення органів військового управління.

1.3 Навчальні цілі

У результаті заняття слухачі повинні:

- розуміти роль даних у системі інформаційно-аналітичного забезпечення;
- знати основні джерела та способи збору даних;
- розрізняти структуровані, напівструктуровані та неструктуровані дані;
- пояснювати етапи життєвого циклу даних;
- визначати основні показники якості даних;
- розуміти призначення баз даних, сховищ даних, озер даних і файлових сховищ;
- обґрунтовувати вибір способу зберігання даних залежно від виду аналітичного завдання;
- враховувати вимоги доступності, цілісності, конфіденційності, резервування та відновлення даних.

1.4 Матеріально-технічне забезпечення

- мультимедійна презентація;
- схема інформаційно-аналітичної системи;
- приклади табличних, текстових, геопросторових і мультимедійних даних;
- демонстраційна база даних;
- персональні комп'ютери або робочі станції;
- засоби візуалізації даних;
- навчальний набір даних.

2 Вступ

Сучасне управління ґрунтується на здатності органу військового управління своєчасно отримувати, узагальнювати, перевіряти та аналізувати значні обсяги різномірної інформації. Початковою основою будь-якого інформаційно-аналітичного продукту є дані.

Без належним чином організованого збору і зберігання даних неможливо забезпечити:

- достовірне оцінювання обстановки;
- виявлення змін і тенденцій;
- прогнозування розвитку ситуації;
- підготовку обґрунтованих пропозицій;
- порівняння варіантів дій;
- підтримку прийняття управлінських рішень;
- накопичення досвіду та повторне використання результатів аналізу.

Дані самі по собі ще не є готовою інформацією. Для набуття практичної цінності вони повинні бути зібрані, перевірені, описані, структуровані, збережені та підготовлені до подальшого аналізу.

У спрощеному вигляді процес перетворення даних на управлінське рішення можна подати так:

Дані → інформація → знання → аналітичний висновок → управлінське рішення.

3 Основні поняття

3.1 Дані

Дані — це формалізоване подання фактів, подій, характеристик об'єктів або результатів спостереження, придатне для передавання, зберігання й автоматизованої обробки.

Прикладами даних можуть бути:

- дата і час події;
- координати об'єкта;
- найменування підрозділу;
- кількісні показники;
- текст повідомлення;
- фотографія або відеозапис;
- електронний документ;
- результат вимірювання;
- запис журналу інформаційної системи;
- оцінка достовірності джерела.

3.2 Інформація

Інформація — це дані, інтерпретовані у певному контексті та придатні для зменшення невизначеності під час прийняття рішення.

Наприклад, окремі координати є даними. Координати, пов'язані з типом об'єкта, часом його виявлення, джерелом повідомлення та оцінкою достовірності, утворюють інформацію, яка може використовуватися в процесі оцінювання обстановки.

3.3 Метадані

Метадані — це дані, які описують інші дані.

До метаданих належать:

- джерело отримання;
- дата і час створення;
- дата і час надходження;
- автор або відповідальний виконавець;
- формат файлу;
- рівень доступу;
- версія документа;
- просторове охоплення;
- система координат;
- термін зберігання;
- оцінка достовірності;
- історія змін.

Метадані дають змогу правильно інтерпретувати дані, знаходити їх у сховищі, контролювати походження та оцінювати придатність до використання.

3.4 Життєвий цикл даних

Життєвий цикл даних охоплює такі основні етапи:

1. визначення інформаційної потреби;
2. створення або отримання даних;
3. передавання даних;
4. первинна перевірка;
5. очищення та перетворення;
6. зберігання;
7. надання доступу;
8. аналіз і використання;
9. архівування;
10. знищення або вилучення після завершення строку зберігання.

4 Навчальне питання 1. Основи збору даних для ІАЗ ОУВ

4.1 Поняття та мета збору даних

Збір даних — це організований процес отримання необхідних відомостей із визначених джерел, їх первинної реєстрації, перевірки та передавання до системи зберігання або обробки.

Метою збору даних є створення повної, актуальної, достовірної та придатної для аналізу інформаційної основи діяльності органу військового управління.

Збір даних повинен відповідати конкретній інформаційній потребі. Накопичення максимально можливої кількості відомостей без визначеної мети створює інформаційне перевантаження, ускладнює пошук і збільшує витрати на обробку та зберігання.

Перед початком збору необхідно відповісти на такі запитання:

- яке рішення має бути підтримане;
- які дані необхідні для прийняття цього рішення;
- хто є споживачем інформації;
- з якою періодичністю необхідно оновлювати дані;
- який рівень точності потрібний;
- які джерела можуть надати потрібні відомості;
- у якому форматі мають надходити дані;
- які обмеження доступу необхідно враховувати.

4.2 Види даних, що використовуються в ІАЗ ОУВ

4.2.1 За формою подання

Вид даних	Характеристика	Приклади
Структуровані	Мають наперед визначену структуру, поля і типи	Таблиці, реєстри, бази даних
Напівструктуровані	Мають елементи структури, але не обов'язково табличну форму	JSON, XML, електронні повідомлення
Неструктуровані	Не мають єдиної формалізованої структури	Тексти, фотографії, відео, аудіо, презентації
Геопросторові	Містять координати, геометрію та просторові атрибути	Карти, маршрути, точки, райони
Часові	Відображають зміну показників у часі	Журнали подій, телеметрія, часові ряди
Мультимедійні	Містять візуальні або звукові матеріали	Фото, відео, аудіозаписи

4.2.2 За походженням

Дані можуть бути:

- **внутрішніми** — створеними всередині органу управління або підпорядкованих структур;
- **зовнішніми** — отриманими від інших органів, установ, інформаційних систем чи відкритих джерел;
- **первинними** — отриманими безпосередньо в результаті спостереження, вимірювання або реєстрації;
- **вторинними** — сформованими на основі обробки, узагальнення чи інтерпретації первинних даних.

4.2.3 За швидкістю надходження

- пакетні дані — передаються через визначені проміжки часу;
- потокові дані — надходять безперервно або майже в реальному часі;
- оперативні повідомлення — передаються у разі настання визначеної події;
- періодична звітність — формується щоденно, щотижнево, щомісячно або за іншим графіком.

4.3 Основні джерела даних

4.3.1 Документи та формалізовані повідомлення

- донесення;
- звіти;
- зведення;
- журнали;
- плани;
- розпорядчі документи;
- електронні картки подій;
- результати виконання завдань.

Перевагою таких джерел є наявність установленної структури. Недоліком може бути затримка між подією та її документальним оформленням.

4.3.2 Інформаційні системи та реєстри

Дані можуть автоматично отримуватися з:

- відомчих інформаційних систем;
- систем електронного документообігу;
- геоінформаційних систем;
- систем управління ресурсами;
- систем моніторингу;
- спеціалізованих реєстрів;
- аналітичних платформ.

4.3.3 Технічні засоби та датчики

До цієї групи належать дані:

- автоматизованого спостереження;
- технічного контролю;
- телеметрії;
- навігаційних систем;
- метеорологічних засобів;
- журналів функціонування обладнання;
- систем контролю мереж і програмного забезпечення.

4.3.4 Людські джерела

Інформація може надходити через:

- доповіді посадових осіб;
- опитування;
- інтерв'ю;
- експертне оцінювання;
- анкетування;

- результати спостереження;
- робочі наради.

Такі дані можуть мати високу цінність, але потребують перевірки через можливу суб'єктивність, неповноту або помилки інтерпретації.

4.3.5 Відкриті джерела

До відкритих джерел можуть належати:

- офіційні вебресурси;
- статистичні портали;
- наукові публікації;
- повідомлення засобів масової інформації;
- супутникові знімки, доступні на законних підставах;
- відкриті картографічні сервіси;
- соціальні мережі;
- відкриті набори даних.

Відомості з відкритих джерел повинні перевірятися, порівнюватися з іншими повідомленнями та оцінюватися з урахуванням надійності джерела.

4.4 Способи збору даних

4.4.1 Ручне введення

Дані вводяться оператором через електронну форму.

Переваги:

- простота реалізації;
- можливість введення нестандартної інформації;
- контроль людиною змісту повідомлення.

Недоліки:

- ризик помилок;
- різне написання однакових значень;
- повільність;
- залежність від підготовки оператора.

Для зменшення кількості помилок доцільно використовувати:

- випадуючі списки;
- довідники;
- перевірку форматів;
- обов'язкові поля;
- маски введення;
- автоматичне заповнення дати та часу;
- перевірку координат;
- попередження про дублювання запису.

4.4.2 Імпорт файлів

Дані завантажуються з файлів CSV, XLSX, JSON, XML або інших форматів.

Перед імпортом необхідно перевіряти:

- кодування тексту;
- назви та порядок полів;
- формат дат;
- одиниці вимірювання;
- систему координат;

- наявність порожніх значень;
- відповідність типів даних;
- відсутність шкідливого вмісту.

4.4.3 Інтеграція через API

API — це програмний інтерфейс, через який одна інформаційна система може автоматично отримувати або передавати дані іншій системі.

Переваги використання API:

- автоматизація обміну;
- зменшення кількості ручних операцій;
- стандартизація форматів;
- можливість оперативного оновлення;
- фіксація часу та результатів обміну.

4.4.4 Потокове отримання даних

Потоковий збір використовується, коли дані надходять постійно й повинні швидко оброблятися.

Типова схема:

Джерело → канал передавання → брокер повідомлень → первинна обробка → сховище → аналітична система.

Потокові дані потребують:

- синхронізації часу;
- контролю черговості повідомлень;
- обробки повторних записів;
- контролю втрати повідомлень;
- механізмів тимчасового накопичення;
- моніторингу затримок.

4.4.5 Автоматизоване вилучення даних із документів

Для опрацювання текстів, таблиць і зображень можуть використовуватися:

- розпізнавання тексту;
- автоматичне виділення реквізитів;
- класифікація документів;
- пошук іменованих сутностей;
- виявлення дат, назв, координат і числових показників;
- перетворення неструктурованого тексту на структуровані записи.

Результати автоматизованого вилучення повинні проходити контроль, особливо якщо вони використовуються для підготовки критично важливих аналітичних висновків.

4.5 Етапи організації збору даних

4.5.1 Етап 1. Визначення інформаційної потреби

Формулюється, які саме відомості потрібні, для якого завдання та в який строк.

4.5.2 Етап 2. Розроблення моделі даних

Визначаються:

- перелік об'єктів;
- характеристики об'єктів;
- обов'язкові поля;
- допустимі значення;
- зв'язки між об'єктами;

- правила оновлення.

4.5.3 Етап 3. Вибір джерел

Джерела оцінюються за:

- доступністю;
- компетентністю;
- надійністю;
- оперативністю;
- повнотою;
- форматом даних;
- обмеженнями щодо використання.

4.5.4 Етап 4. Визначення способу отримання

Обирається ручне введення, імпорт файлів, API, потокове передавання або поєднання кількох способів.

4.5.5 Етап 5. Первинна реєстрація

Під час реєстрації до даних додаються:

- унікальний ідентифікатор;
- час події;
- час отримання;
- джерело;
- відповідальний оператор;
- рівень доступу;
- ознака версії;
- оцінка достовірності.

4.5.6 Етап 6. Перевірка

Перевіряється правильність формату, логічна узгодженість, повнота, наявність дублювання та допустимість значень.

4.5.7 Етап 7. Очищення і нормалізація

До основних операцій належать:

- виправлення форматів;
- усунення зайвих пробілів;
- уніфікація назв;
- приведення дат до єдиного формату;
- перетворення одиниць вимірювання;
- стандартизація координат;
- об'єднання дубльованих записів;
- позначення відсутніх значень.

4.5.8 Етап 8. Передавання до сховища

Перевірені дані завантажуються до бази даних, файлового сховища, озера даних або іншого визначеного середовища.

4.6 Конвеєр підготовки даних

У практиці інформаційно-аналітичних систем використовується процес ETL:

1. **Extract — вилучення:** отримання даних із джерел.
2. **Transform — перетворення:** очищення, перевірка, стандартизація та збагачення.
3. **Load — завантаження:** запис підготовлених даних до цільового сховища.

Альтернативним підходом є ELT:

1. вилучення;
2. завантаження до масштабованого сховища;
3. подальше перетворення безпосередньо в середовищі зберігання.

ETL доцільний, коли до сховища повинні надходити вже перевірені й уніфіковані дані. ETL використовується, коли необхідно зберігати значні обсяги первинних даних і виконувати різні варіанти їх подальшої обробки.

4.7 Якість даних

Якість даних визначає придатність даних для виконання конкретного інформаційно-аналітичного завдання.

4.7.1 Основні характеристики якості

Характеристика	Зміст
Повнота	Наявність усіх необхідних значень
Точність	Відповідність даних фактичному стану
Достовірність	Ступінь довіри до джерела та змісту
Актуальність	Відповідність даних поточному моменту
Своєчасність	Надходження даних у визначений строк
Узгодженість	Відсутність суперечностей між записами
Унікальність	Відсутність необґрунтованих дублікатів
Валідність	Відповідність установленим форматам і правилам
Простежуваність	Можливість установити походження та історію змін

4.7.2 Коефіцієнт повноти

$$K_{\text{повн}} = \frac{N_{\text{заповнених обов'язкових значень}}}{N_{\text{усіх обов'язкових значень}}}$$

Якщо з 100 обов'язкових значень заповнено 92, коефіцієнт повноти становить:

$$K_{\text{повн}} = \frac{92}{100} = 0,92.$$

4.7.3 Коефіцієнт валідності

$$K_{\text{вал}} = \frac{N_{\text{коректних записів}}}{N_{\text{перевірених записів}}}$$

4.7.4 Коефіцієнт своєчасності

$$K_{\text{своєч}} = \frac{N_{\text{даних, отриманих у встановлений строк}}}{N_{\text{усіх отриманих даних}}}$$

4.7.5 Коефіцієнт унікальності

$$K_{\text{унік}} = \frac{N_{\text{унікальних записів}}}{N_{\text{усіх записів}}}$$

4.7.6 Інтегральний показник якості

Для узагальненого оцінювання може використовуватися зважена модель:

$$Q = \sum_{i=1}^m w_i q_i,$$

де Q — інтегральний показник якості; q_i — оцінка окремої характеристики; w_i — ваговий коефіцієнт характеристики; $\sum w_i = 1$.

Наприклад:

$$Q = 0,25 K_{\text{повн}} + 0,25 K_{\text{вал}} + 0,30 K_{\text{своєч}} + 0,20 K_{\text{унік}}.$$

Ваги повинні визначатися з урахуванням призначення конкретного набору даних.

4.8 Перевірка достовірності даних

Достовірність не завжди можна встановити тільки автоматично. Для її оцінювання доцільно застосовувати:

- порівняння з незалежними джерелами;
- перевірку внутрішньої логіки повідомлення;
- аналіз попередньої надійності джерела;
- перевірку часу і місця події;
- аналіз метаданих;
- установлення першоджерела;
- виявлення ознак редагування;
- експертне оцінювання;
- повторне спостереження або уточнення.

У системі доцільно окремо зберігати:

- факт або повідомлення;
- джерело;
- рівень надійності джерела;
- рівень підтвердження відомостей;
- метод перевірки;
- дату останньої перевірки.

Необхідно розрізняти:

- відсутність даних;
- нульове значення;
- невідоме значення;
- значення, яке ще перевіряється;
- значення, яке не може бути розкрито через обмеження доступу.

4.9 Типові проблеми збору даних

4.9.1 Дублювання

Одна подія може бути зареєстрована кількома джерелами або кілька разів передана одним джерелом.

Для виявлення дублювання використовуються:

- унікальні ідентифікатори;
- порівняння часу;
- порівняння координат;
- контрольні суми;
- аналіз подібності тексту;
- правила об'єднання записів.

4.9.2 Різні формати

Одна дата може бути подана як:

- 06.08.2026;
- 2026-08-06;
- 06/08/2026;
- 6 серпня 2026 року.

Для автоматизованого аналізу всі значення повинні приводитися до єдиного стандарту.

4.9.3 Різні одиниці вимірювання

Показники можуть подаватися в метрах, кілометрах, милях, секундах, хвилинах або годинах. Одиниця вимірювання повинна бути явно визначена в моделі даних.

4.9.4 Розбіжності в часі

Необхідно розрізняти:

- час настання події;
- час фіксації;
- час створення повідомлення;
- час передавання;
- час отримання;
- час внесення до системи.

4.9.5 Втрата контексту

Окреме числове значення без пояснення може бути неправильно інтерпретоване. Тому разом із даними необхідно зберігати контекст і метадані.

5 Навчальне питання 2. Основи зберігання даних для ІАЗ ОУВ

5.1 Поняття та завдання зберігання даних

Зберігання даних — це організоване розміщення даних на визначених носіях або в інформаційних системах із забезпеченням їх доступності, цілісності, захищеності, пошуку, відновлення та подальшого використання.

Основними завданнями зберігання є:

- збереження отриманих даних;
- забезпечення швидкого пошуку;
- підтримання актуальної версії;
- збереження історії змін;
- розмежування доступу;
- резервне копіювання;
- відновлення після відмов;
- архівування;
- контроль строків зберігання;
- забезпечення можливості аналітичної обробки.

5.2 Основні вимоги до систем зберігання

5.2.1 Доступність

Уповноважені користувачі повинні мати доступ до необхідних даних у встановлений час.

Коефіцієнт доступності може визначатися як:

$$A = \frac{T_{\text{роботи}}}{T_{\text{роботи}} + T_{\text{простою}}}.$$

5.2.2 Цілісність

Дані не повинні бути несанкціоновано або випадково змінені, пошкоджені чи видалені.

5.2.3 Конфіденційність

Доступ до даних повинні мати лише уповноважені користувачі та системи.

5.2.4 Масштабованість

Система повинна підтримувати збільшення:

- кількості записів;
- кількості користувачів;
- швидкості надходження;
- кількості джерел;
- складності аналітичних запитів.

5.2.5 Продуктивність

Сховище повинно забезпечувати прийнятний час:

- запису;
- пошуку;
- фільтрації;
- агрегування;
- передавання результатів;
- формування звітів.

5.2.6 Простежуваність

Необхідно мати можливість визначити:

- хто створив запис;
- хто переглядав дані;
- хто вніс зміни;
- коли відбулася зміна;
- яке значення було до зміни;
- з якого джерела надійшли дані.

5.3 Основні способи зберігання

5.3.1 Файлове зберігання

Дані зберігаються у вигляді окремих файлів і каталогів.

Приклади:

- текстові документи;
- електронні таблиці;
- презентації;
- фотографії;
- відеозаписи;
- архіви;
- файли JSON або CSV.

Переваги:

- простота;
- зручність для документів і мультимедіа;
- можливість роботи зі стандартними програмами.

Недоліки:

- складність контролю версій;
- можливість дублювання;
- обмежені можливості одночасної роботи;
- складність пошуку за змістом;
- недостатній контроль зв'язків між даними.

Файлове сховище доцільно використовувати для зберігання документів і великих мультимедійних об'єктів, але метадані про ці файли бажано зберігати в базі даних.

5.3.2 Реляційні бази даних

У реляційній базі дані організовані у вигляді таблиць, пов'язаних між собою.

Приклади систем:

- PostgreSQL;
- MySQL;
- Microsoft SQL Server;
- Oracle Database;
- SQLite.

Реляційні бази доцільні для даних із чіткою структурою:

- об'єкти;
- події;
- підрозділи;
- ресурси;
- документи;
- завдання;
- показники;
- користувачі;
- довідники.

Переваги:

- контроль типів даних;
- підтримка зв'язків;
- зменшення дублювання;
- складні запити;
- транзакційність;
- механізми контролю цілісності;
- розмежування доступу.

Приклад структури таблиці подій:

Поле	Тип	Призначення
event_id	Унікальний ідентифікатор	Ідентифікація події
event_time	Дата і час	Час події
received_time	Дата і час	Час отримання
source_id	Ідентифікатор	Джерело
event_type	Текст або код	Тип події
latitude	Число	Географічна широта
longitude	Число	Географічна довгота
description	Текст	Опис
confidence	Число або категорія	Оцінка достовірності
access_level	Код	Рівень доступу
created_by	Ідентифікатор	Автор запису

5.3.3 Документоорієнтовані бази даних

Дані зберігаються у вигляді документів, найчастіше у форматі JSON.

Приклад запису:

```
{
  "event_id": "EVT-2026-00125",
  "event_time": "2026-08-06T08:15:00+03:00",
  "source": {
    "source_id": "SRC-017",
    "source_type": "information_system"
  },
  "event_type": "observation",
  "location": {
    "latitude": 50.4501,
    "longitude": 30.5234
  },
  "confidence": 0.82,
  "status": "verified"
}
```

Переваги:

- гнучкість структури;
- зручність роботи з JSON;
- можливість зберігати вкладені об'єкти;
- швидке створення прототипів.

Недоліки:

- складніший контроль зв'язків;
- можливе дублювання даних;
- необхідність додаткового контролю структури.

5.3.4 Бази часових рядів

Призначені для даних, що надходять із часовими мітками:

- телеметрії;
- показників стану;
- результатів моніторингу;
- завантаження систем;
- даних датчиків;
- журналів подій.

Основні операції:

- отримання значень за період;
- визначення мінімуму та максимуму;
- розрахунок середніх значень;
- виявлення аномалій;
- порівняння часових інтервалів;
- прогнозування.

5.3.5 Геопросторові бази даних

Геопросторові бази використовуються для зберігання:

- точок;
- маршрутів;
- ліній;
- районів;
- меж;
- зон;
- шарів електронної карти.

Вони підтримують запити:

- які об'єкти розташовані в заданому районі;
- яка відстань між двома об'єктами;
- які маршрути перетинають визначену зону;

- які події відбулися в заданому радіусі;
- які об'єкти найближчі до визначеної точки.

Для роботи з геопросторовими даними може застосовуватися PostgreSQL із розширенням PostGIS.

5.3.6 Графові бази даних

Графова база даних подає інформацію як:

- вузли — об'єкти;
- ребра — зв'язки між об'єктами;
- властивості — характеристики вузлів і зв'язків.

Такий підхід може використовуватися для аналізу:

- організаційних зв'язків;
- залежностей між подіями;
- інформаційних потоків;
- мережевої взаємодії;
- зв'язків між документами;
- ланцюгів причин і наслідків.

5.3.7 Сховище даних

Сховище даних — централізована система, призначена для інтеграції історичних даних із різних джерел та виконання аналітичних запитів.

Основні властивості:

- предметна орієнтованість;
- інтегрованість;
- збереження історії;
- відносна незмінність завантажених даних;
- оптимізація для аналітики.

У сховищі даних можуть створюватися окремі **вітрини даних** для конкретних структурних підрозділів або функціональних напрямів.

5.3.8 Озеро даних

Озеро даних — масштабоване середовище, у якому зберігаються первинні структуровані, напівструктуровані та неструктуровані дані.

В озері можуть зберігатися:

- таблиці;
- журнали;
- JSON-документи;
- зображення;
- відео;
- аудіо;
- геопросторові файли;
- результати моделей;
- архіви.

Перевага озера даних полягає у можливості зберегти первинний матеріал для подальшої обробки. Водночас без каталогізації, метаданих і правил управління озеро даних може перетворитися на некероване накопичення файлів.

5.3.9 Архітектура Lakehouse

Lakehouse поєднує:

- гнучкість озера даних;

- структурованість сховища даних;
- підтримку аналітичних запитів;
- контроль схем;
- ведення версій;
- можливість використання даних для машинного навчання.

5.4 Порівняння основних способів зберігання

Спосіб	Доцільне застосування	Основне обмеження
Файлове сховище	Документи, фото, відео	Складність пошуку та контролю зв'язків
Реляційна база	Структуровані взаємопов'язані дані	Потреба у визначеній схемі
Документна база	Гнучкі JSON-документи	Складніший контроль узгодженості
База часових рядів	Потокові показники та телеметрія	Вузька спеціалізація
Геопросторова база	Карти, координати, райони	Потреба у спеціальних засобах
Графова база	Аналіз складних зв'язків	Відмінна від табличної логіка роботи
Сховище даних	Звіти, історична аналітика	Значні витрати на інтеграцію
Озеро даних	Великі обсяги різнорідних даних	Ризик недостатньої впорядкованості
Lakehouse	Аналітика та машинне навчання	Вища складність побудови

5.5 Рівні зберігання даних

5.5.1 Рівень 1. Первинні дані

Зберігаються у вигляді, максимально наближеному до отриманого від джерела. Це забезпечує можливість повторної перевірки та обробки.

5.5.2 Рівень 2. Очищені дані

Дані перевірені, нормалізовані, очищені від технічних помилок і приведені до єдиних форматів.

5.5.3 Рівень 3. Інтегровані дані

Відомості з різних джерел об'єднані відповідно до єдиної моделі.

5.5.4 Рівень 4. Аналітичні набори

Дані підготовлені для конкретних завдань:

- розрахунку показників;
- побудови графіків;
- геопросторового аналізу;
- прогнозування;
- навчання моделей;
- формування звітів.

5.5.5 Рівень 5. Архів

Зберігаються історичні дані, які рідко використовуються, але мають довгострокову цінність.

5.6 Оцінювання необхідного обсягу сховища

Орієнтовний обсяг зберігання можна оцінити за формулою:

$$V = N \cdot S \cdot T \cdot K_{\text{рез}} \cdot K_{\text{служ}},$$

де V — потрібний обсяг сховища; N — кількість записів за одиницю часу; S — середній розмір одного запису; T — тривалість зберігання; $K_{\text{рез}}$ — коефіцієнт резервування або реплікації; $K_{\text{служ}}$ — коефіцієнт службових витрат.

Наприклад, якщо система отримує 100 000 записів на добу, середній розмір запису становить 2 КБ, а дані зберігаються протягом 365 діб:

$$V_{\text{баз}} = 100000 \cdot 2 \cdot 365 = 73\,000\,000 \text{ КБ.}$$

До цього обсягу необхідно додати витрати на:

- індекси;
- журнали;
- резервні копії;
- репліки;
- метадані;
- проміжні результати;
- зростання обсягів.

5.7 Індексация та пошук

Індекс — додаткова структура, яка прискорює пошук даних.

Доцільно створювати індекси для полів, за якими часто здійснюються:

- пошук;
- сортування;
- фільтрація;
- об'єднання таблиць;
- групування.

Типові поля для індексації:

- дата і час;
- унікальний ідентифікатор;
- тип події;
- джерело;
- статус;
- координати;
- рівень доступу.

Надмірна кількість індексів може уповільнювати запис даних і збільшувати обсяг сховища. Тому індекси повинні створюватися відповідно до реальних аналітичних запитів.

5.8 Резервне копіювання та відновлення

Резервне копіювання забезпечує можливість відновлення даних після:

- технічної відмови;
- пошкодження носія;
- помилки користувача;
- помилки програмного забезпечення;
- несанкціонованої зміни;
- втрати основного сховища.

5.8.1 Основні види резервних копій

- **повна копія** — містить усі визначені дані;
- **диференційна копія** — містить зміни після останньої повної копії;
- **інкрементальна копія** — містить зміни після останнього резервного копіювання;
- **знімок стану** — фіксує стан системи на визначений момент.

5.8.2 Показник RPO

RPO — Recovery Point Objective визначає максимально допустимий обсяг даних, який може бути втрачений, виражений у часі.

Наприклад, RPO 30 хвилин означає, що після відмови допускається втрата даних не більше ніж за останні 30 хвилин.

5.8.3 Показник RTO

RTO — Recovery Time Objective визначає максимально допустимий час відновлення роботи системи.

Наприклад, RTO 2 години означає, що система повинна бути відновлена не пізніше ніж через дві години після відмови.

Резервні копії необхідно не лише створювати, а й регулярно перевіряти шляхом тестового відновлення.

5.9 Реплікація даних

Реплікація — створення та підтримання копій даних на кількох серверах або майданчиках.

Вона може забезпечувати:

- підвищення доступності;
- розподіл навантаження;
- швидше відновлення;
- географічне резервування;
- безперервність роботи.

Реплікація не замінює резервне копіювання, оскільки помилкове видалення або пошкодження даних може автоматично поширитися на всі репліки.

5.10 Захист даних

Захист повинен охоплювати весь життєвий цикл даних: від створення до знищення.

5.10.1 Основні заходи

- автентифікація користувачів;
- розмежування прав;
- рольова або атрибутна модель доступу;
- шифрування каналів передавання;
- шифрування носіїв;
- журналювання дій;
- контроль цілісності;
- резервне копіювання;
- сегментація інформаційної інфраструктури;
- контроль експорту;
- блокування неактивних облікових записів;
- регулярний перегляд прав доступу;
- безпечне видалення;
- навчання користувачів.

5.10.2 Принцип найменших привілеїв

Користувач або програмний компонент повинен мати лише ті права, які необхідні для виконання його функцій.

5.10.3 Розподіл ролей

Доцільно відокремлювати:

- власника даних;
- адміністратора системи;
- адміністратора бази даних;

- оператора введення;
- аналітика;
- споживача аналітичної інформації;
- фахівця з інформаційної безпеки;
- аудитора.

5.11 Керування версіями та історією змін

Під час оновлення даних важливо не лише зберігати поточне значення, а й забезпечувати можливість установити попередній стан.

Запис історії може містити:

- ідентифікатор об'єкта;
- попереднє значення;
- нове значення;
- час зміни;
- автора зміни;
- причину зміни;
- посилання на підтверджувальний документ.

Це дає змогу:

- відновлювати попередні значення;
- аналізувати розвиток ситуації;
- установлювати відповідальність;
- виявляти помилки;
- забезпечувати аудит.

5.12 Каталог даних

Каталог даних — систематизований опис доступних наборів даних.

Для кожного набору доцільно зазначати:

- назву;
- призначення;
- власника;
- джерело;
- структуру;
- формат;
- періодичність оновлення;
- рівень доступу;
- показники якості;
- строк зберігання;
- відповідального адміністратора;
- допустимі способи використання.

Каталог допомагає уникати повторного збору однакової інформації та дає аналітику змогу знайти потрібний набір даних.

5.13 Політика зберігання

Політика зберігання повинна визначати:

- які дані зберігаються;
- хто є власником;
- де розташовується основна копія;
- скільки часу зберігаються дані;
- коли дані переводяться до архіву;

- хто має право доступу;
- як здійснюється резервне копіювання;
- як проводиться відновлення;
- коли та як дані знищуються;
- як документується історія використання.

Строк зберігання повинен визначатися не довільно, а відповідно до призначення даних, їх цінності, правових вимог і вимог керівних документів.

6 Узагальнена архітектура збору та зберігання даних

Типову архітектуру можна подати у вигляді таких рівнів.

6.1 Рівень 1. Джерела

- документи;
- оператори;
- інформаційні системи;
- реєстри;
- датчики;
- відкриті джерела;
- зовнішні бази.

6.2 Рівень 2. Інтеграція

- електронні форми;
- API;
- імпорт файлів;
- брокери повідомлень;
- засоби розпізнавання;
- ETL- та ELT-процеси.

6.3 Рівень 3. Контроль якості

- перевірка форматів;
- нормалізація;
- усунення дублікатів;
- оцінка достовірності;
- збагачення метаданими;
- реєстрація помилок.

6.4 Рівень 4. Зберігання

- реляційні бази;
- документні бази;
- геопросторові бази;
- файлові сховища;
- озера даних;
- архіви.

6.5 Рівень 5. Аналітика

- запити;
- статистична обробка;
- геопросторовий аналіз;
- машинне навчання;
- прогнозування;
- виявлення аномалій.

6.6 Рівень 6. Представлення

- інформаційні панелі;
- карти;
- графіки;
- зведення;
- аналітичні записки;
- попередження;
- автоматизовані звіти.

Над усіма рівнями повинні діяти механізми:

- управління доступом;
- моніторингу;
- журналювання;
- резервування;
- контролю якості;
- управління метаданими.

7 Навчальний приклад

7.1 Умова

Орган військового управління отримує повідомлення про події з декількох джерел:

- електронної форми;
- таблиці CSV;
- зовнішньої інформаційної системи через API;
- текстових документів.

Необхідно забезпечити формування єдиного реєстру подій і відображення перевірених даних на електронній карті.

7.2 Запропонований процес

1. Кожне джерело передає дані до модуля інтеграції.
2. Даним присвоюється унікальний ідентифікатор.
3. Перевіряються дата, час, координати та тип події.
4. Назви об'єктів приводяться до значень єдиного довідника.
5. Виконується пошук можливих дублікатів.
6. Дані зберігаються в таблиці первинних повідомлень.
7. Після перевірки формується запис у таблиці підтверджених подій.
8. Документи, фото та відео зберігаються у файловому сховищі.
9. Посилання на файли та їх метадані зберігаються в базі даних.
10. Геопросторові поля обробляються засобами геопросторової бази.
11. Зміни фіксуються в журналі аудиту.
12. Перевірені події відображаються на інформаційній панелі.

7.3 Рекомендована структура

- PostgreSQL — для структурованих записів;
- PostGIS — для координат і просторових операцій;
- файлове або об'єктне сховище — для документів і мультимедіа;
- API — для автоматизованого обміну;
- модуль ETL — для очищення й інтеграції;
- інформаційна панель — для візуалізації;
- система резервного копіювання — для відновлення даних.

8 Практична вправа 1. Проектування збору даних

Слухачам пропонується визначити порядок збору даних для підготовки щоденного інформаційно-аналітичного зведення.

Необхідно визначити:

1. основних споживачів інформації;
2. перелік необхідних показників;
3. джерела даних;
4. періодичність надходження;
5. формат передавання;
6. обов'язкові поля;
7. правила перевірки;
8. критерії достовірності;
9. відповідальних осіб;
10. порядок дій у разі відсутності або суперечності даних.

Очікуваний результат:

Показник	Джерело	Періодичність	Формат	Відповідальний	Спосіб перевірки
----------	---------	---------------	--------	----------------	------------------

9 Практична вправа 2. Вибір сховища

Для кожного виду даних необхідно обрати доцільний спосіб зберігання.

Дані	Рекомендований варіант
Реєстр подій	Реляційна база даних
Координати та райони	Геопросторова база даних
Фотографії та відеозаписи	Файлове або об'єктне сховище
Журнали технічних показників	База часових рядів
Документи зі змінною структурою	Документна база або файлове сховище
Зв'язки між об'єктами	Графова база даних
Історичні дані для звітності	Сховище даних
Великі первинні набори	Озеро даних

Слухачі повинні обґрунтувати свій вибір за критеріями:

- структура;
- обсяг;
- швидкість надходження;
- частота оновлення;
- спосіб пошуку;
- вимоги до історії;
- рівень доступу;
- потреба в аналітичній обробці.

10 Ситуаційне завдання

У базі даних виявлено три записи:

Час	Координати	Тип	Джерело	Опис
08:10	50.4500, 30.5230	Спостереження	Джерело 1	Виявлено об'єкт
08:12	50.4502, 30.5232	Спостереження	Джерело 2	Виявлено об'єкт
08:14	50.4500, 30.5230	Спостереження	Джерело 1	Повторне повідомлення

10.1 Питання для обговорення

1. Чи є ці записи дублюванням?
2. Які додаткові поля потрібні для прийняття рішення?
3. Чи потрібно видаляти повторні записи?
4. Як зберегти інформацію про всі джерела?
5. Як визначити достовірність події?
6. Який запис повинен відображатися на інформаційній панелі?
7. Як зберегти історію об'єднання записів?

10.2 Методичний висновок

Повторні повідомлення не завжди потрібно фізично видаляти. Доцільно зберігати первинні повідомлення окремо, а підтверджену подію формувати як самостійний об'єкт, пов'язаний з усіма джерелами.

11 Типові помилки під час організації зберігання

1. Зберігання всіх даних в одній великій таблиці.
2. Використання електронних таблиць замість багатокористувацької бази даних.
3. Відсутність унікальних ідентифікаторів.
4. Зберігання різних значень в одному полі.
5. Використання довільного тексту замість довідників.
6. Відсутність метаданих.
7. Перезапис даних без збереження історії.
8. Відсутність резервних копій.
9. Відсутність тестового відновлення.
10. Надання надмірних прав користувачам.
11. Зберігання копій одного файлу в різних каталогах.
12. Відсутність єдиних форматів дати, часу та координат.
13. Відсутність політики архівування.
14. Змішування первинних і перевірених даних.
15. Відсутність відповідального власника набору даних.

12 Методичні рекомендації викладачу

Під час розкриття першого навчального питання доцільно:

- показати слухачам декілька різних форматів одного повідомлення;
- запропонувати визначити обов'язкові поля;
- продемонструвати наслідки помилкової дати або координат;
- пояснити різницю між подією і повідомленням про подію;
- продемонструвати приклад дублювання;
- звернути увагу на важливість метаданих.

Під час розкриття другого навчального питання доцільно:

- порівняти папку з файлами та базу даних;
- показати просту таблицю PostgreSQL;
- продемонструвати пошук за датою, типом і районом;
- пояснити різницю між оперативною базою і сховищем даних;
- показати приклад резервної копії;

- обговорити наслідки втрати або несанкціонованої зміни даних.

13 Контрольні запитання

1. Що таке дані та чим вони відрізняються від інформації?
2. Яку роль відіграють метадані?
3. Які етапи охоплює життєвий цикл даних?
4. Які дані називаються структурованими?
5. Наведіть приклади напівструктурованих даних.
6. Які основні джерела даних використовуються в ІАЗ ОУВ?
7. У чому полягає відмінність пакетного і потокового збору?
8. Що таке API?
9. Які операції виконуються в межах ETL?
10. Чим ELT відрізняється від ETL?
11. Які характеристики визначають якість даних?
12. Як розрахувати коефіцієнт повноти?
13. Чому повторні повідомлення не завжди потрібно видаляти?
14. Для чого використовуються унікальні ідентифікатори?
15. Чим реляційна база відрізняється від файлового сховища?
16. Для яких даних доцільно використовувати геопросторову базу?
17. Що таке сховище даних?
18. Чим озеро даних відрізняється від сховища даних?
19. Що визначають показники RPO і RTO?
20. Чому реплікація не замінює резервне копіювання?
21. У чому полягає принцип найменших привілеїв?
22. Для чого необхідно зберігати історію змін?
23. Яке призначення каталогу даних?
24. Які наслідки може мати відсутність єдиної моделі даних?
25. Які способи захисту повинні застосовуватися під час зберігання даних?

14 Завдання для самостійної роботи

14.1 Завдання 1

Розробити перелік полів для електронної картки події, яка повинна містити:

- ідентифікатор;
- час;
- місце;
- джерело;
- опис;
- тип;
- статус;
- оцінку достовірності;
- рівень доступу;
- посилання на додаткові матеріали.

Для кожного поля визначити:

- тип даних;
- обов'язковість;
- допустимі значення;
- правило перевірки.

14.2 Завдання 2

Побудувати схему руху даних:

джерело → отримання → перевірка → очищення → зберігання → аналіз → візуалізація.

Для кожного етапу зазначити:

- відповідального;
- вхідні дані;
- вихідні дані;
- можливі помилки;
- спосіб контролю.

14.3 Завдання 3

Порівняти PostgreSQL, документну базу даних і файлове сховище за критеріями:

- структура;
- пошук;
- масштабованість;
- контроль зв'язків;
- зберігання мультимедіа;
- історія змін;
- складність адміністрування.

15 Висновки

Збір і зберігання даних є базовими процесами інформаційно-аналітичного забезпечення органів військового управління. Якість аналітичного продукту безпосередньо залежить від повноти, точності, актуальності, достовірності та своєчасності початкових даних.

Ефективний збір даних передбачає:

- чітке визначення інформаційної потреби;
- вибір надійних джерел;
- використання стандартизованих форматів;
- реєстрацію метаданих;
- перевірку якості;
- очищення та нормалізацію;
- контроль дублювання;
- простежуваність походження.

Ефективне зберігання передбачає:

- вибір архітектури відповідно до типу даних;
- розмежування первинних, очищених та аналітичних даних;
- забезпечення доступності, цілісності та конфіденційності;
- ведення історії змін;
- резервне копіювання і тестування відновлення;
- каталогізацію;
- архівування;
- контроль строків зберігання.

Головним принципом є не накопичення максимальної кількості даних, а створення керованого інформаційного середовища, у якому кожен набір даних має визначене джерело, призначення, структуру, власника, рівень якості та правила використання.